

26 大创人工智能眼底-中期汇报

一、数据集介绍

1.1 DDR (Diabetic Retinopathy Dataset) 数据集概述

本项目使用的核心数据集为 DDR (Diabetic Retinopathy Dataset)，这是一个专为糖尿病视网膜病变病灶分割与疾病分级设计的大规模公开数据集。DDR 数据集收集了来自多家医疗机构、不同拍摄条件下的眼底图像，具有高度的临床多样性和现实挑战性。

1.1.1 数据集基本构成

分割任务包含 757 张眼底图像，配备像素级的四种典型 DR 病灶标注 (EX、HE、MA、SE)，总计包含 486 个 EX 标注、601 个 HE 标注、570 个 MA 标注和 239 个 SE 标注。分类任务 (0-4 级五分类) 涉及更多图像，数据呈现出极度显著的长尾分布：Class 0 (正常) 2,825 张、Class 1 (轻度) 279 张、Class 2 (中度) 1,797 张、Class 3 (重度) 99 张、Class 4 (增殖期) 386 张，训练集中 Class 1 和 Class 3 样本极其稀缺。

1.1.2 图像分辨率范围

DDR 数据集中的图像分辨率从 1500×1100 像素到 3200×2400 像素 不等，由不同操作人员在不同条件下拍摄，图像尺寸和质量差异显著。这种多样性对模型的泛化能力提出了极高要求。

1.1.3 分割任务类别统计

根据我们的训练集统计，各类病灶像素占比极度不平衡：

类别	像素数	占比 (%)	背景与该类别像素比
Background (背景)	87,796,031	99.09%	—
MA (微血管瘤)	32,379	0.037%	2,712 : 1
HE (出血)	452,458	0.511%	194 : 1
EX (硬性渗出)	238,607	0.269%	368 : 1
SE (软性渗出)	85,197	0.096%	1,031 : 1
前景合计	808,641	0.91%	109 : 1

在 DDR 中，MA (微动脉瘤) 是最难检测的类别——仅占训练像素的 0.037%，背景与 MA 像素比高达 2,712:1。即使在前景采样的策略下，每个 Batch 中 MA 出现的频率依然极低，这是所有模型在 MA 上表现不佳的根本原因。

1.1.4 数据划分统计差异

我们注意到三个划分之间各类别像素分布存在显著差异：

划分	总像素（约）	背景占比	MA 占比	HE 占比	EX 占比	SE 占比
训练集	88,604,672	99.09%	0.037%	0.511%	0.269%	0.096%
验证集	39,059,456	99.56%	0.031%	0.216%	0.071%	0.126%
测试集	54,525,952	98.94%	0.022%	0.622%	0.377%	0.036%

关键观察：EX 在测试集中的占比（0.377%）约为验证集（0.071%）的 5.3 倍，直接导致 EX 的测试集 IoU 远高于验证集；SE 在测试集中的占比（0.036%）仅为验证集（0.126%）的 29%，是 SE 测试集性能骤降的直接原因；三个划分之间类别分布存在明显统计差异，表明数据集未按像素比例进行严格的分层采样。

1.1.5 学术背景参考

本课题研究中另一个常被使用的参考数据集为 IDRiD（Indian Diabetic Retinopathy Image Dataset），它由 516 张眼底图像组成，图像分辨率统一为 4288×2848 像素（45°视野），并提供像素级的 EX、HE、MA、SE 标注以及 0-4 级疾病分级。IDRiD 的标注质量高、病灶相对明显，常用作 DR 分割任务的基准测试集。然而，DDR 在数据规模、临床多样性和现实挑战性上远超 IDRiD，我们认为 DDR 的复现结果对临床落地更具参考价值。

1.2 分类任务数据集与长尾挑战

本项目旨在对糖尿病视网膜病变（Diabetic Retinopathy, DR）进行精确的 0-4 级五分类诊断（0: 无病变, 1: 轻度, 2: 中度, 3: 重度, 4: 增殖期）。

核心挑战：数据呈现极度的长尾分布（Class 0 和 2 数据庞大，而 Class 1 和 3 极度稀缺，特别是 Class 1 微动脉瘤具有病患早期特征，病灶小、检出难的特点）。直接使用标准分类模型极易沦为被多数类主导的“偏科”模型。

二、自搭建模型（YOLO+UNet）

2.1 YOLO 模型（分类+分割）

2.1.1 YOLO 模型介绍

本项目使用的 YOLO 模型包括两个任务：

YOLO11s-cls（分类）：用于糖尿病视网膜病变 0-4 级五分类诊断。基础架构为 YOLO11s-cls 预训练分类基座。

YOLO-Seg（分割）：用于病灶分割，在 YOLO11 的 C3k2 骨干网络与解耦检测头之间嵌入了 SIMAM 注意力机制。

2.1.2 所用模块介绍

2.1.2.1 分类任务模块

- Ben Graham 对比度增强：预处理步骤，用于抹平局部光照不均，使血管和出血点跨越

背景凸显。

- **Focal Loss (焦点惩罚):** 全面替换原生交叉熵。使用训练集分布[2825, 279, 1797, 99, 386]通过公式生成精巧的权重，再配合 $\text{Gamma}=2.0$ ，专门把梯度资源倾斜给罕见类（Class 1/3）。
- **Ordinal Penalty (序数距离约束):** 给 YOLO 加上医学临床评测逻辑。跨级误诊（比如把正常误诊为 4 级晚期增殖恶性）越离谱，再额外叠加一分动态惩罚乘数：
$$\text{abs(pred_class - target)} * 0.2$$
。

2.1.1.2 分割任务模块

- **SIMAM 3D 注意力机制的特征解耦头:** 在 YOLO11 的 C3k2 骨干网络与解耦检测头之间嵌入 SIMAM (Simple Parameter-Free Attention Module)，使模型在特征提取阶段自动聚焦于病灶区域，增强对细小目标的感知。
- **多尺度权重平衡的复合损失函数 (Hybrid Focus-Dice Loss):** 采用 Focal Loss 调整难易样本权重，并耦合 Tversky Loss (Dice Loss 的泛化版) 精细调节 FP 与 FN 的权衡。
- **针对性切片训练 (Targeted Patch Training):** 通过算法自动扫描标注框，将每个含有病灶的区域切割成小图喂给 YOLO-Seg，解决背景淹没前景的问题。
- **两阶段推理流水线(Two-Stage Inference Pipeline):** 测试时先使用 Detection 模型扫描全图定位潜在病灶点，将检测到的区域动态切割成小图送入分割模型，再还原到原图坐标。

2. 1. 3 训练策略

2.1.3.1 分类任务

阶段一：基础模型构建与训练

输入分辨率：384×384

Epochs: 50 轮

Batch Size: 16

优化器：AdamW (lr0=0.0005, weight_decay=0.0005)

防止过拟合：高强度数据增强 (Flip、HSV、RandAugment) 及 Label Smoothing (0.1)

阶段二：进阶微调 (继承阶段一权重)

分辨率拉升：512×512

学习率：1e-4 (极小步调，防止洗掉阶段一骨架特征)

Batch Size: 16

Epochs: 60 轮

损失函数：Focal Loss + Ordinal Penalty

2.1.3.2 分割任务

本次训练采用了特殊的“小图切片”接力微调，关键参数见下表：

参数项	设定值	优化意图
-----	-----	------

参数项	设定值	优化意图
数据源策略	Small Image Cropping	核心策略: 将大图根据分割标注切割成包含病灶的小图片, 极大提升前景占比。
输入分辨率	1024 x 1024	保留更多 MA 边缘细节, 减少小目标丢失。
Batch Size	4	显存极限下的最佳批次。
学习率 (lr0)	0.0001 (1e-4)	极小步长保证在小图分布下的稳定收敛。

推理实现方案 (Deployment Strategy)

- 全局初筛: 由后端轻量级识别模型或 Detection 扫过全图, 输出所有可能存在病变的 Bounding Boxes。
- 图像裁剪: 根据输出框, 以中心点进行局部 Crop。由于分割模型是基于小图训练的, 其对 Crop 后的画面具有极强的适应性。
- 高清分割: 将 Crop 后的高清小图送入本 YOLO-Seg 模型, 产出精细的 Mask 掩码。
- 原图还原: 将小图 Mask 重新贴回原图坐标系, 生成最终的全图分割诊断报告。

2.1.4 结果

2.1.4.1 分类任务结果

阶段一结果: 整体准确率 80.2%。能在数量大的 Class 0、2、4 上准确率极高, 但 Class 1 (轻度) 检出率仅约 17%, Class 3 几乎被模型无视。

改良模型测试集跑分 (Test Split Verification)

利用刚刚微调出来的改良模型对独立 Test 集 (3531 张没经过训练的眼底图) 进行实测:

全局准度 - Top-1 Accuracy: 81.20%

各病程细分召回率 (Recall) 表现:

病程类别	样本 (Test)	成功检出	最终召回率	评价与进步
0: 正常	2142	1839	85.85%	保留极高特异性, 不会成为 “一见黑影就报警” 的模型
1: 轻度	177	49	27.68%	相比此前 17%, 精准捕获能力大增
2: 中度	998	814	81.56%	稳固的主力诊断区间底盘
3: 重度	52	27	51.92%	全库极度罕见类别 (1.4%), 准确率大大上升
4: 增殖期	162	139	85.80%	重病极少错失最佳干预时机

可视化评估:

下面是由上述微调后最新推理产出的混淆矩阵。深色块响应准确沿着对角线排布，以往彻底发白的 Class 1 和 3 这次点亮了明显的热区。




图 1 绝对数量分布矩阵 (Confusion Matrix)



图 2 百分比归一化矩阵 (Normalized Confusion Matrix)

2.1.4.2 分割任务结果

基于验证集（以切片后的分布进行评估）的跑分如下：

分割指标 (Mask Metrics)

mAP@50 (M): 31.61%

Precision (M): 41.54%

Recall (M): 37.12%

总结：采用切片策略后，模型对细小病灶的敏感度大幅提升，Precision (41.54%) 表明切割后的图像让模型对病灶边缘的判断更加自信。

可视化评估：




图 3 训练过程曲线




图 4 绝对数量分布矩阵 (Confusion Matrix)




图 5 百分比归一化矩阵 (Normalized Confusion Matrix)




图 6 验证集推理示例 1




图 7 验证集推理示例 2

2.1.5 问题与分析

2.1.5.1 分类模型

分类模型虽然通过全阶段优化使 Top-1 准确率达到 81.20%，并利用 Focal Loss 和序数惩罚点亮了罕见类的热区，但混淆矩阵反映出其在临床诊断落地中仍存在严重隐患：

1.早期轻度病变 (Class 1) 向中度 (Class 2) 严重“过诊断”

现象数据: 在 177 例真实的 Class 1 (轻度) 患者中, 仅有 49 例被正确检出 (召回率 27.68%), 而竟然有 117 例被误诊为了 Class 2 (中度), 误诊率高达 66%。

分析：临床上 Class 1 与 Class 2 的核心区别通常在于微动脉瘤（MA）的数量以及是否存在少许出血点。分类基座（YOLO11s-cls）即使分辨率拉升到了 512x512，其本质上依然是通过全局池化（Global Pooling）压缩特征。这种机制擅长捕捉“有无”特征，但不擅长捕获“数量/密度”特征。模型看到了 MA 信号，但由于无法精确计数，直接将其归类为了数据量更大、特征更明显的 Class 2 底盘。

2.重度病变（Class 3）向中度（Class 2）发生“漏诊”

现象数据：52 例真实的 Class 3（重度）患者中，有 20 例被漏诊为了 Class 2（中度），误诊率达 38.5%。

分析：Class 3（重度 NPDR）要求病灶满足特定的“4-2-1 规则”（如 4 个象限有严重出血）。模型将重度误诊为中度，说明其对全局病灶的空间分布、象限覆盖率缺乏宏观建模能力。512x512 的分辨率可能让网络无法看清全底图中大面积分布的微小血管瘤细节，导致信息缺失，做出了保守的降级预测，这在临床上具有很高的医疗风险。

3.正常眼底（Class 0）的假阳性偏高

现象数据：有 258 例正常（Class 0）眼底被误诊为了 Class 2（中度）。

分析：报告中提到实施了 Ben Graham 对比度增强。这种预处理是一把双刃剑：它在抹平局部光照不均、凸显血管的同时，也会将眼底的非病变伪影（如相机反光、脉络膜背景杂色、噪声）强行放大。分类模型受到这些被放大的伪影干扰，误认为存在病灶，从而将正常眼底错误“点亮”为中度病变。

2.1.5.2 分割模型

虽然报告中提到采用“切片策略”后模型对边缘的判断更加自信，但从混淆矩阵的绝对数量和归一化结果来看，该分割模型仍存在以下严峻的技术瓶颈：

1.极高的漏检率

现象数据：MA（微动脉瘤）：共有 2553 个真实病灶，其中高达 2125 个被误判为 background（背景），漏检率高达 83.2%（归一化显示为 0.83）。

HE（出血点）、EX（硬性渗出）、SE（软性渗出）：被误判为背景的比例分别高达 61%、66% 和 61%。

模型的整体召回率（Recall）仅为 37.12%。

分析：即使采用了“局部切割训练（Targeted Patch Training）”来强行提高前景比例，但在 1024x1024 的高分辨率切片中，健康背景像素的数量依然绝对碾压 MA 等微小病灶。YOLO-Seg 这种基于锚框或无锚框的检测分割架构，在处理像素占比极低的超小目标时，其特征图在多次下采样后，微小病灶的语义信息容易在高级特征图中丢失，导致网络倾向于保守地预测为背景。

背景区域误报

现象数据：在预测为病灶的区域中，有大量真正的背景被误判。例如：有 839 个背景区域被预测为 MA，572 个背景区域被预测为 EX。这直接导致模型的精准率（Precision）停留在 41.54% 的较低水平。

分析：眼底图像中的脉络膜血管纹理、视盘边缘、视网膜色素沉着等正常生理结构，在局部 Crop 放大到 1024x1024 后，其局部边缘特征与 MA 或 EX 极度相似。

2.病灶间的交叉误诊

现象数据：有 77 个 True HE 被误判为了 MA。

分析：MA（微动脉瘤）和早期点状 HE（出血点）在形态学上都是红色小圆点，极难区分。虽然引入了 SimAM 3D 注意力机制进行特征解耦，但对于这种“同色异质”的极细微临床特征，模型在颜色与纹理的辨析度上仍显不足。

2.2 UNet 模型（分割）

2.2.1 UNet 介绍

本项目自构建的标准 U-Net 架构，由编码器、解码器和跳跃连接构成，直接接受原始图像输入并输出分割掩膜。在此基础上新增了五个独立模块，专门针对眼底图像的类别极度不平衡问题进行优化。

2.2.2 所用模块介绍

2.2.2.1 CLAHE + Gamma 图像预处理

背景

眼底图像中，微血管瘤（MA）等病灶对比度极低，直接输入网络时易被背景淹没。本项目在图像送入网络之前，新增了一套针对眼底图像的对比度增强预处理流程。

- CLAHE（对比度受限自适应直方图均衡化）

将图像从 RGB 色彩空间转换为 LAB 色彩空间，仅对亮度通道（L 通道）施加 CLAHE，避免对色彩信息的干扰。参数设置：clip_limit = 2.0, tile_size = 8×8。该操作能显著提升局部区域的对比度，clip_limit 同时限制了噪声放大的上限。

- Gamma 矫正（ $\gamma = 0.8$ ）

对 CLAHE 增强后的图像施加 Gamma 矫正。 $\gamma < 1$ 使图像整体变亮，改善暗色眼底背景下病灶区域的辨识度，尤其对低亮度的 MA 病灶有明显帮助。

- 完整预处理流程：

RGB → LAB → CLAHE（L 通道）→ LAB → RGB → Gamma 矫正 → 归一化至 [0, 1]

2.2.2.2 前景偏置 Patch 采样策略（ForegroundPatchDataset）

问题根源

标准训练方式将整张图像缩放至 512×512 后送入网络。但眼底图像的背景像素占 99.09%，导致损失函数的梯度信号几乎完全由背景主导，模型收敛到全部预测为背景的退化解（类别崩塌，mIoU = 0）。此外，原始图像分辨率通常在 2000×3000 像素以上，MA 病灶缩放至 512×512 后仅剩约 1-3 像素，接近分辨率下限。

核心机制

从原始分辨率图像上裁剪 512×512 的 Patch，而非对全图等比缩放。每个 Epoch 生成 1500 个 Patch，采样比例如下：

80% 为前景 Patch：以某一病灶多边形的质心为中心进行裁剪，多边形以面积加权随机采样，面积越大的病灶被选中概率越高；

20% 为随机背景 Patch：从图像中随机位置裁剪，保证模型仍能学习背景区域的特征。

内存缓存

训练开始时将全部 338 张原始图像及其标注掩膜一次性加载至内存（约 1-2 GB），彻底消除训练过程中的磁盘 I/O 瓶颈，显著提升训练速度。

每 Epoch 重新采样

每个 Epoch 独立重建 Patch 索引，确保模型每轮训练见到不同的 Patch 组合，避免对固定 Patch 序列的过拟合。

2.2.2.3 Focal Tversky Loss

设计动机

标准 CrossEntropyLoss 对所有像素等权对待，在 109:1 的背景/前景比下，模型会迅速退化为全背景预测。本项目采用 Focal Tversky Loss (Abraham & Khan, IEEE ISBI 2019) 作为最终损失函数。

Tversky Index 定义

对于第 c 类前景 (c = 1, 2, 3, 4) :

$$TI_c = (TP + \epsilon) / (TP + \alpha \cdot FP + \beta \cdot FN + \epsilon)$$

其中 TP 为真正例，FP 为假正例，FN 为假负例， $\epsilon = 1.0$ 为平滑项，防止分母为零。

Focal Tversky Loss 定义

$$FTL = (1/C) \cdot \sum (1 - TI_c)^\gamma$$
，对所有前景类求均值，背景类 (c=0) 排除在外

参数设置

参数	取值	含义
$\alpha = 0.3$	0.3	对假正例 (FP) 惩罚较轻
$\beta = 0.7$	0.7	对漏检 (FN) 惩罚较重
$\gamma = 0.75$	0.75	对难样本适度聚焦
$\epsilon = 1.0$	1.0	平滑项，防止零除

$\beta > \alpha$ 的设计使损失对漏检 (FN) 的惩罚约为误检 (FP) 的 2.3 倍，契合医学图像分割中宁可误报、不可漏检的实际需求。

2.2.2.4 学习率调度器 (ReduceLROnPlateau)

在 Adam 优化器基础上，配置 ReduceLROnPlateau 调度策略：当验证集损失连续 5 个 Epoch 不下降时，将当前学习率乘以 0.5。该策略使模型在训练前期以较大步长快速收敛，在后期以更小步长精细调整参数，避免在最优解附近震荡。

2.2.2.5 早停机制 (Early Stopping)

为防止在 338 张小数据集上过拟合，新增早停机制：当验证集损失连续 20 个 Epoch 均未改善时，自动终止训练，并保留历史上验证集损失最低时对应的模型权重 (checkpoint) 作为最终模型。最大训练轮数设为 100 Epochs。

2.2.3 训练策略

2.2.3.1 训练配置总览

配置项	值
优化器	Adam
初始学习率	3×10^{-4}
Batch Size	4
最大训练轮数	100 Epochs
每 Epoch Patch 数	1500
前景 Patch 比例	80%
学习率调度	ReduceLROnPlateau (factor=0.5, patience=5)
早停耐心值	20 Epochs
损失函数	Focal Tversky Loss ($\alpha=0.3$, $\beta=0.7$, $\gamma=0.75$)

2.2.3.2 训练阶段演进

在最终方案确定之前，共经历了四个训练阶段：

阶段	损失函数	数据采样	预处理	结果
阶段一	CrossEntropyLoss (均匀权重)	全图缩放 512×512	无	类别崩塌, mIoU = 0
阶段二	DiceCE (50% Dice + 50% CE)	全图缩放 512×512	无	轻微改善, 仍接近崩塌
阶段三	DiceCE + 类别权重	全图缩放 512×512	无	仍然崩塌
阶段四(当前)	Focal Tversky Loss	ForegroundPatch 采样	CLAHE + Gamma	成功检测 MA、HE、EX

阶段一至三的失败揭示了一个核心规律：仅修改损失函数不足以解决 109:1 的类别不平衡问题。必须从数据采样层面同步介入，确保每个 Batch 中前景像素占有足够比例，损失函数的梯度信号才能真正作用于病灶检测学习。

2. 2. 4 结果

2.2.4.1 验证集结果

类别	IoU	备注
Background (背景)	0.9877	
MA (微血管瘤)	0.0193	检测效果极弱
HE (出血)	0.0490	低水平检测
EX (硬性渗出)	0.1593	最优前景类
SE (软性渗出)	0.0000	完全未检测
前景平均 mIoU	0.0569	
像素准确率	0.9867	因类别不平衡，意义有限

2.2.4.2 测试集结果

类别	IoU	备注
Background（背景）	0.9824	
MA（微血管瘤）	0.0122	较验证集更低
HE（出血）	0.0800	较验证集略有提升
EX（硬性渗出）	0.2940	显著提升（数据分布差异）
SE（软性渗出）	0.0000	完全未检测
前景平均 mIoU	0.0965	
像素准确率	0.9816	因类别不均衡，意义有限

2.2.5 问题与分析

2.2.5.1 SE 类别完全未被检测（IoU = 0）

SE（软性渗出）在验证集和测试集上的 IoU 均为 0.0000，模型对该类病灶的检测能力为零。

原因分析：

训练集中 SE 多边形标注仅 1,207 个，约为 EX（21,566 个）的 1/18，监督信号极度稀缺；SE 像素仅占训练集总像素的 0.096%，即使在 80% 前景采样中，SE Patch 的出现频率依然极低；

SE 与 EX 在外观上高度相似（均呈亮白色斑块状），模型难以建立有效的区分特征。

2.2.5.2 MA 检测效果极弱（IoU ≤ 0.02）

MA（微血管瘤）验证集 IoU 仅 0.0193，测试集进一步降至 0.0122，检测效果极为有限。

原因分析：

MA 是所有类别中最稀少的，仅占训练像素的 0.037%，背景与 MA 像素比高达 2,712:1；原始图像缩放至 512×512 后，MA 病灶的直径约为 1–3 像素，接近卷积核能够感知的分辨率下限；

微血管瘤在视觉上表现为极小的暗色圆点，与正常血管分支及图像噪声难以区分。

2.2.5.3 EX 测试集结果显著优于验证集（0.1593 → 0.2940）

EX（硬性渗出）测试集 IoU（0.2940）比验证集（0.1593）高出 84.7%，并非模型泛化能力的提升，而是数据集划分的统计差异所致。

原因分析：

测试集中 EX 像素占比为 0.377%，而验证集中仅为 0.071%，即测试集中的硬性渗出病灶面积普遍更大；

较大面积的病灶在视觉特征上更加显著，模型更易捕捉；IoU 的计算对大面积正确预测更友好。

2.2.5.4 像素准确率的误导性

验证集像素准确率为 0.9867，测试集为 0.9816，数值看似较高。然而在背景像素占 99% 以上的数据集中，仅凭背景预测的正确率就能拉高整体准确率，该指标在本场景下不具备评估意义。真正能反映病灶检测能力的指标为前景类别的 mIoU 和各类别 Dice 系数。

2.2.5.5 与 SMP 复现模型的差距

模型	验证集 mIoU	测试集 mIoU	SE 验证集 IoU
自构建 U-Net	0.0569	0.0965	0.0000
SMP U-Net (ResNet34)	0.1073	0.1212	0.1163

SMP 模型的整体性能约为自构建模型的 1.9 倍，最显著的差异在于 SE 类别：自构建模型完全无法检测 SE (IoU = 0)，而 SMP 能达到 IoU = 0.1163。核心差距在于：SMP 使用了在 ImageNet 上预训练的 ResNet34 编码器，其通用视觉特征（边缘、纹理、颜色斑块）为稀少类别的学习提供了有力的初始表示；而自构建 U-Net 在仅有 338 张图像的条件下完全从随机初始化开始训练，特征提取能力的差距显著。

三、已复现模型（M2MRF、HRDecoder、SMP）

3.1 M2MRF 糖尿病视网膜病变病灶分割

3.1.1 原论文摘要

特征重组（Feature reassembly）是现代基于 CNN 的分割方法中的一个关键组成部分，包含特征下采样和上采样算子。现有算子独立地为每个目标位置，从一个小的预定义区域内将多个特征重组为一个特征。这可能导致空间信息丢失，尤其是当微小病灶聚集在一起时，其激活信号可能因此而消失。在本文中，我们提出了一种多对多的特征重组方法（M2MRF）。该方法在降维后的特征空间中进行特征重组，同时将一个大预定义区域内的多个特征聚合为多个目标特征。通过这种方式，捕获长距离空间依赖关系，从而维持微小病灶上的激活信号。在两个病灶分割基准数据集（DDR 和 IDRiD）上的实验结果表明：（1）我们的 M2MRF 优于现有的特征重组算子；（2）配备了 M2MRF 的 HRNetv2 能够取得显著优于基于 CNN 的分割方法的性能，并且与两种最新的基于 Transformer 的分割方法相比具有竞争力甚至更好的性能。

代码：<https://github.com/CVIU-CSU/M2MRF-Lesion-Segmentation>。

3.1.2 复现配置

模型配置：

配置项	参数值
Backbone	HRNet_M2MRF_A（预训练：msra/hrnetv2_w48）

Decode Head	FCNHead (in_channels=[48,96,192,384], channels=720)
输入分辨率	1024 × 1024
分类数	4 (EX、HE、SE、MA) + 背景
损失函数	BinaryLoss (Dice, smooth=1e-5)
M2MRF patch size	(8, 8)
M2MRF encode rate	4
M2MRF fc rate	64
use_sigmoid	True

训练配置：

配置项	参数值
优化器	SGD (lr=0.01, momentum=0.9, weight_decay=5e-4)
学习率策略	Poly Decay (power=0.9, min_lr=1e-4, by_epoch=False)
总迭代次数	60,000
Batch Size	1 sample/GPU × 1 GPU
图像均值	[81.205, 50.636, 21.216] (RGB)
图像标准差	[76.252, 48.798, 21.625] (RGB)
数据增强	Resize(0.5~2.0)、RandomCrop(1024)、PhotoMetricDistortion
数据集	DDR (data/DDR)
显存占用	~10,022 MB (约 9.8 GB)

训练时间：约 6.5 小时

3.1.3 结果

3.1.3.1 训练过程

Binary Dice Loss 从初始约 1.0 下降至 0.62 左右，整体收敛平稳。训练初期（0~10K iter）损失快速下降约 16%，中期（10K~40K iter）进入缓慢收敛阶段，后期（40K~60K iter）损失稳定在 0.62~0.65 区间。

3.1.3.2 整体评估指标（测试集，全局汇总）

以下为训练结束后在 DDR 测试集上的评估结果：

类别	IoU (%)	F1 (%)	PPV (%)	Sensitivity	AUPR
----	---------	--------	---------	-------------	------

				(%)	
bg	0.70	1.40	94.39	0.70	0.00
EX（硬性渗出）	0.09	0.18	0.09	34.80	0.00
HE（出血）	0.52	1.03	0.57	5.43	0.00
SE（软性渗出）	0.14	0.28	0.14	28.13	0.00
MA（微动脉瘤）	0.00	0.00	NaN	0.00	0.00
全局 (mIoU)	0.19	0.37	0.20	17.09	0.00

3.1.3.3 逐图像 IoU 统计（DDR 测试集，208 张图像）

以下统计来自 iou_ddr_test.csv，共 208 张测试图像的每类 IoU 数据：

统计项	EX (%)	HE (%)	SE (%)	MA (%)
平均 IoU（含零值）	12.05	16.11	29.13	3.62
平均 IoU（仅非零样本）	26.96	23.60	43.59	41.80
最大 IoU	67.49	73.32	77.00	91.31
非零样本数 / 总数	93 / 208	142 / 208	139 / 208	18 / 208
非零样本占比	44.7%	68.3%	66.8%	8.7%
标准差	16.96	18.80	25.04	14.07



图 8 视觉识别示例

3.1.3.4 结果分析

1. SE（软性渗出）表现最佳：SE 类在非零样本上平均 IoU 达到 43.59%，最高单图 IoU 达到 77.00%，整体 mIoU（29.13%）也最高，说明该类病灶尺寸相对较大，模型可以较好地捕捉其空间特征。

2. MA（微动脉瘤）为最难类别：MA 仅有 18 张图像（8.7%）产生非零 IoU，整体 mIoU 仅 3.62%，反映了 MA 病灶极小（微米级）、在 1024x1024 分辨率下像素占比极低的特性。日志中 MA 的 F1=0.00、PPV=NaN，说明模型几乎未能正确预测 MA，与论文强调微小病灶分割挑战性一致。

3. 全局 mIoU 偏低（0.19）：日志中的全局 mIoU 是将所有类（含背景 bg）纳入计算并除以 5 得到，其中 bg IoU=0.70 和 MA IoU $\approx$ 0.00 拉高/拉低了均值。若仅考虑 4 个病灶类（EX、HE、SE、MA），对应 mIoU $\approx (0.09+0.52+0.14+0.00)/4 \approx 0.19$ ，与论文原始指标体系有所不同，需注意评估口径的差异。

4. 逐图方差较大：各类标准差均远高于均值（如 SE 标准差 25.04 vs 均值 29.13），且每类均有大量零值样本，表明模型在不同图像上的分割一致性有待提升，可能与 DDR 数据集本身标注密度不均、病灶出现率差异显著有关。

3.1.4 问题与讨论

3.1.4.1 与论文数值的对比

本次复现以 mIoU 作为主要评估口径。当前复现结果中 HE 的 Dice（F1）约为 1.03%（全局平均），SE 约为 0.28%，与论文中相应 Dice 存在明显差距。

3.1.4.2 训练收敛情况

从损失曲线来看，模型在 60K iter 内整体收敛正常，最终 Dice Loss $\approx$ 0.62。由于 Binary Dice Loss 的理论下界受背景类主导影响，0.62 的最终损失处于合理范围。后期损失波动较大（约 ± 0.05 ）

3.2 HRDecoder (High-Resolution Decoder Network for Fundus Image Lesion Segmentation)

3.2.1 原论文摘要

高分辨率对于眼底图像的精确分割至关重要，然而处理高分辨率输入会带来相当大的 GPU 显存开销，且随着计算负担的增加，性能提升会逐渐减弱。为了解决这一问题，同时应对微小目标分割的挑战，近期研究探索了局部-全局融合方法。这些方法利用局部区域保

留精细细节，并从下采样的全局图像中捕获长程上下文信息。然而，多次前向传播的需求不可避免地带来了显著的计算开销，对推理速度产生不利影响。在本文中，我们提出了 HRDecoder，一个用于眼底病变分割的简单高分辨率解码器网络。它集成了一个高分辨率表示学习模块来捕获细粒度的局部特征，以及一个高分辨率融合模块来融合多尺度预测结果。我们的方法在保持合理的显存和计算开销以及满足令人满意的推理速度的同时，有效提高了眼底病变的整体分割精度。在 IDRiD 和 DDR 数据集上的实验结果证明了我们方法的有效性。

3.2.2 复现配置

硬件与软件环境：

配置项	详情
GPU	NVIDIA RTX 4080 SUPER (显存 ~31 GB)
平台	AutoDL 云服务器
操作系统	Linux (Ubuntu 20.04)
Python	3.8.10
PyTorch	2.0.1 + CUDA 11.8
MMCV	1.7.2
MMSegmentation	0.16.0
CuDNN	8.7

模型架构：

本次复现采用 HRDecoder + FCNHead 方案，backbone 为 HRNet-W48，在 MSRA 上预训练（open-mmlab://msra/hrnetv2_w48），解码头采用 7×7 卷积 FCNHead，输出 4 通道对应 4 类病灶。训练时使用 sigmoid 逐类激活（use_sigmoid=True），损失函数为 BinaryDice Loss，高分辨率辅助监督权重为 0.1。

训练超参数：

超参数	设置值
优化器	SGD (lr=0.01, momentum=0.9, wd=5e-4)
学习率调度	Poly LR (power=1.0) + Linear Warmup 1500 iters
训练迭代数	40,000 iterations
Batch Size	1 (samples_per_gpu=1)
输入分辨率	2048 × 2048
数据增强	RandomFlip(0.5) + RandomRotate(±45°) + RandomCrop + Resize(0.5~2.0)
评估间隔	每 4000 iterations
保存策略	每 1000 iterations 保存，保留最新 1 个 + best mIoU

3.2.3 训练过程分析

3.2.3.1 学习率调度

如图 1 所示，学习率从接近零线性预热至初始值 0.01（前 1500 次迭代），随后以 Poly 衰减策略单调下降至约零，确保训练初期参数稳定更新、后期精细收敛。




图 9 学习率调度曲线 (Poly LR + 线性预热)

3.2.3.2 训练损失曲线

如图 10 所示，训练从 Iter 10000（已从 checkpoint 续训）开始记录，总损失（Total Loss）由高分辨率辅助损失（HR Loss，权重 0.1）和主融合分割损失（Fuse Loss，权重 1.0）构成。从曲线走势可以观察到：

- HR Loss 从约 0.097 平稳下降至约 0.070，整体较小且稳定，说明高分辨率监督信号有效
- Fuse Loss 从约 0.878 下降至约 0.570，构成总损失的主体部分，下降趋势明显
- 训练后期（30000 iter 以后）损失曲线已较平稳，说明模型基本收敛




图 10 训练损失曲线 (Total / Fuse / HR Loss, 10-point 移动平均平滑)

3.2.3.3 验证集指标趋势

图 11 展示了训练过程中验证集上 mIoU、mF1、mAUPR 三项指标随迭代次数的变化。从中可以得出以下结论：

- mIoU 整体呈先升后震荡趋势，在 Iter 20000 达到峰值 28.51%，为最优 checkpoint
- mAUPR 在 Iter 16000~20000 区间出现明显提升（最高 44.23%），与 mIoU 趋势一致
- 训练后期各指标有所波动但未出现显著退化，说明模型在学习率降低后有进一步微调




图 11 验证集指标趋势（mIoU / mF1 / mAUPR，每 4000 iter 评估一次）

3.2.4 实验结果

3.2.4.1 最优模型性能（Iter 20000）

Best Checkpoint 在 DDR 测试集上的完整逐类别评估结果如下表所示（均以百分比形式展示）：

类别	IoU (%)	F1 (%)	PPV (%)	S (%)	AUPR (%)	MAE ($\times 10^{-2}$)
EX	16.57	28.43	31.06	26.21	23.49	0.08
HE	27.81	43.52	77.35	30.27	53.75	0.66
SE	34.84	51.67	84.31	37.25	62.41	0.38
MA	24.81	39.76	41.36	38.29	37.25	0.25
全局均值	28.51	40.85	58.52	33.00	44.23	0.34

3.2.4.2 各类别性能可视化

如图 12 所示，SE（软性渗出）在 IoU、F1、AUPR 三项指标上均表现最优，而 EX（硬性渗出）因形态多样、边界模糊，各指标相对偏低。MA（微动脉瘤）虽 PPV 仅 41.36%，但召回率（S=38.29%）较均衡，体现了其小目标检测的难度。




图 12 各类别 IoU / F1 / AUPR 对比（Best Checkpoint, Iter 20000）

3.2.4.3 多次验证结果汇总

下表汇总了训练过程中所有 8 次验证的全局均值指标，便于观察模型收敛趋势：

验证 Iter	mIoU (%)	mF1 (%)	mPPV (%)	mS (%)	mAUPR (%)	mMAE
4000	23.04	36.60	48.73	37.12	39.75	0.0038
8000	20.76	33.36	47.01	38.35	38.49	0.0044
12000	22.17	35.77	53.64	29.80	38.10	0.0036
16000	21.74	35.39	60.29	27.96	42.55	0.0033
20000	28.51	40.85	58.52	33.00	44.23	0.0034
24000	24.60	38.97	48.28	37.28	40.49	0.0037
28000	22.90	36.82	57.15	30.56	41.96	0.0033
32000	25.07	39.54	53.26	34.56	41.58	0.0036
36000	22.90	36.82	57.15	30.56	41.96	0.0033
40000	25.07	39.54	53.26	34.56	41.58	0.0036

3.2.5 分析与讨论

3.2.5.1 性能瓶颈分析

EX 类别 IoU 仅 16.57%，明显低于其他类别，主要原因包括：

- EX 形态极不规则，从细小点状到大片融合渗出均有，特征学习难度大
- DDR 数据集中 EX 标注存在一定噪声，影响监督信号质量
- Batch Size=1 导致 BN 统计不稳定，对多形态病灶泛化能力受限

SE 类别表现最优（IoU 34.84%），主要原因：

- SE 通常呈较规则的圆形棉絮状，特征相对稳定，易于学习
- SE 尺寸较大，在 2048 分辨率下占像素比例更高，有利于分割

3.2.5.2 HE 精确率偏高的原因

HE 的 PPV（77.35%）远高于其 IoU（27.81%），说明模型预测 HE 时精确率很高但召回率偏低（S=30.27%），即"宁缺毋滥"的倾向——对于出现的预测基本正确，但漏检严重。这符合 HE 形态多样、部分出血较小且颜色与背景相近的特点。

3.2.5.3 后续改进方向

基于以上分析，后续实验计划从以下方向进行改进：

- 尝试 Batch Size=2 或梯度累积，提升 BatchNorm 稳定性
- 延长训练至 80,000 iter，观察是否能进一步提升 mIoU
- 对 EX 类引入额外的类别权重，缓解类别不均衡问题

3.3 SMP (Segmentation Models Pytorch)

3.3.1 模型介绍

SMP（Segmentation Models Pytorch）是一个开源的语义分割工具库，集成了 DeepLab、U-Net、FPN、PSPNet 等主流分割架构。本实验使用的配置为 U-Net + ResNet34 编码器 + ImageNet 预训练权重。ResNet34 编码器提供了经过大规模自然图像预训练的深度特征提取能力，通过跳跃连接将低层细节与高层语义融合，是当前通用分割任务的标准基线之一。

3.3.2 复现结果

3.3.2.1 验证集结果

类别	Dice 系数	IoU	备注
Background（背景）	0.9950	0.9901	
MA（微血管瘤）	0.0726	0.0376	检测能力极弱

HE（出血）	0.1811	0.0996	低水平检测
EX（硬性渗出）	0.2990	0.1758	最优前景类
SE（软性渗出）	0.2083	0.1163	有效检测（预训练贡献）
前景均值	0.1902	0.1073	

3.3.2.2 测试集结果

类别	Dice 系数	IoU	备注
Background（背景）	0.9923	0.9848	
MA（微血管瘤）	0.0502	0.0258	较验证集下降
HE（出血）	0.2274	0.1283	较验证集提升
EX（硬性渗出）	0.4629	0.3011	大幅提升（数据分布差异）
SE（软性渗出）	0.0573	0.0295	大幅下降（测试集 SE 极少）
前景均值	0.1995	0.1212	

3.3.3 问题讨论

3.3.3.1 EX 性能在测试集显著提升的原因

EX（硬性渗出）测试集 Dice 从 0.2990 跃升至 0.4629，IoU 从 0.1758 升至 0.3011，涨幅约为 55% - 70%。

核心原因：数据分布差异，而非模型泛化能力的提升

- 测试集中 EX 像素占比（0.377%）约为验证集（0.071%）的 5.3 倍，测试集中硬性渗出病灶的平均面积显著更大；
- IoU 指标对大面积病灶在计算上更宽松——单次分割误差对大病灶的 $TP/(TP+FP+FN)$ 比值影响较小；
- 较大面积的 EX 病灶具有更明显的视觉特征（亮白色高对比度区域），模型更容易检测。

结论：这是数据集划分不均匀导致的统计偏差，并非模型在测试集上的真实泛化提升。如需可靠评估，需确保各划分中 EX 像素占比相近。

3.3.3.2 SE 性能在测试集骤降的原因

SE（软性渗出）验证集 Dice 0.2083 / IoU 0.1163，测试集 Dice 仅 0.0573 / IoU 0.0295，下降幅度超过 70%。

- 数据稀缺性（首要原因）

测试集中 SE 像素占比仅 0.036%，而验证集为 0.126%（约为测试集的 3.5 倍）。测试集中 SE 病灶极少，模型一旦漏检一个区域，IoU 便会出现断崖式下降。

- SE 与 EX 外观相似

软性渗出与硬性渗出在颜色和形态上具有较高相似度，模型可能将部分 SE 区域误判为 EX，导致 SE 的召回率偏低。

- 训练样本不足

训练集中仅有 1,207 个 SE 多边形，模型对该类别本身的学习就已不充分，在测试集

上的泛化能力必然有限。

3.3.3.3 MA 检测效果持续偏低的原因

MA（微血管瘤）验证集 IoU = 0.0376，测试集 IoU = 0.0258，两个划分均处于极低水平。

- 分辨率瓶颈（核心制约）

原始眼底图像分辨率通常超过 2000×3000 像素，MA 在原图中的直径约为 20 - 40 像素。缩放至 512×512 后，MA 直径压缩至约 3 - 8 像素，极易与图像噪声及微小血管分支混淆。

- 极度稀少

MA 仅占训练像素的 0.037%，背景/MA 像素比高达 2,712:1。即便使用 ImageNet 预训练权重和类别权重（CE 权重 4×），模型可获得的 MA 梯度信号仍然极为有限。

- 类内形态多样性

微血管瘤因患者个体差异和图像拍摄质量变化，形态、大小和对比度差异较大，增加了跨样本学习的难度。

3.3.3.4 验证集与测试集指标差异的整体评估

类别	验证集 IoU	测试集 IoU	变化方向	主要原因
MA	0.0376	0.0258	↓ 下降	测试集 MA 像素更稀少（0.022% vs 0.031%）
HE	0.0996	0.1283	↑ 上升	测试集 HE 占比更高（0.622% vs 0.216%）
EX	0.1758	0.3011	↑ 大幅上升	测试集 EX 像素约为验证集 5.3 倍
SE	0.1163	0.0295	↓ 大幅下降	测试集 SE 极少（0.036% vs 0.126%）

整体而言，验证集与测试集之间的 IoU 波动主要源于数据集划分的类别像素分布不均匀，而非模型在两个集合上存在系统性的泛化差异。这一问题在数据量小、类别极度稀少的医学图像分割任务中普遍存在。

3.3.3.5 与自构建 U-Net 的对比及预训练的作用

模型	验证集 mIoU	测试集 mIoU	SE 验证集 IoU
自构建 U-Net（从零训练）	0.0569	0.0965	0.0000
SMP U-Net （ResNet34/ImageNet）	0.1073	0.1212	0.1163

SMP 模型在所有指标上均优于自构建模型。最显著的差异在于 SE 类别：自构建模型完全无法检测 SE（IoU = 0），而 SMP 能达到 IoU = 0.1163。这表明 ImageNet 预训练权重所提供的通用视觉特征（边缘检测、纹理识别、颜色斑块感知）有助于检测稀少类别，弥补了训练数据不足的缺陷；而这是在仅有 338 张图像、从随机初始化开始训练时难以获得的。

3.3.3.6 当前性能与公开基准的差距

模型	mIoU（验证/测试）	备注
FCN-8s（DDR 基准）	约 0.08–0.12	公开基准参考（Li et al. 2019）
SegNet（DDR 基准）	约 0.10–0.14	公开基准参考
U-Net（DDR 基准）	约 0.15–0.22	公开基准参考
SMP ResNet34（本项目）	0.1073 / 0.1212	当前最优结果

本项目 SMP 复现的验证集 mIoU 为 0.1073，仍低于公开基准中 U-Net 的 0.15–0.22。差距主要来源于以下四点：

- 训练数据量不足：本项目仅使用 338 张训练图像，远少于公开基准中的数据规模；
- MA 和 SE 检测能力弱：这两类稀少类别的低 IoU 显著拉低了前景平均 mIoU；
- 缺少数据增强：未使用几何变换、颜色抖动等在医学图像分割中常用的数据增强手段；
- 输入分辨率限制：统一缩放至 512×512 对 MA 等微小目标不友好，损失了原图中的细节信息。

四、未来工作规划

整体分两个阶段推进。

4.1 主流架构横向对比

在统一的数据管线（ForegroundPatchDataset + CLAHE 预处理 + Focal Tversky Loss）下，依次训练并评估以下几类代表性架构，以前景 mIoU 和各类别 Dice 为主要指标进行横向比较：纯 CNN 类选取 DeepLabV3+（ResNet50/ResNet101 backbone）和 HRNet-W48；CNN-Transformer 混合类选取 TransUNet 和 Swin-UNet；此外充分利用已有代码，将项目中已实现的 HRDecoder 和 M2MRF 一并纳入对比。所有模型使用相同的训练轮数（50 Epoch）、相同的早停策略和相同的验证集指标进行评估，保证对比的公平性。通过这一轮横评，识别出在 MA、HE、EX、SE 四类病灶上综合表现最优的基础架构，作为第二阶段的优化起点。

4.2 对选定模型的系统性优化

4.2.1 训练策略层面

将当前固定学习率的 ReduceLROnPlateau 替换为带 Warmup 的余弦退火调度（前 5 Epoch 线性升温，此后余弦衰减），并引入混合精度训练（AMP）以降低显存占用、支持更大 Batch Size；同时在验证集 Dice 连续无提升时触发渐进式学习率重启，避免陷入局部极值。

4.2.2 数据处理与增强层面

针对 SE 和 MA 两类稀少类别实施按类配额的强制采样，保证每个 Epoch 中 SE Patch 不少于固定数量；在现有 CLAHE 预处理基础上叠加随机颜色抖动（亮度、对比度、饱和度小幅扰动）和随机几何变换（水平翻转、随机旋转），提升模型对眼底图像拍摄角度差异的鲁棒性；此外引入 CopyPaste 增强——将训练集中 SE 和 MA 病灶区域随机粘贴至背景图像上，人工扩充稀少类别的样本数量。

4.2.3 新模块层面

重点针对识别出的性能瓶颈展开：若 MA 检测仍弱，引入动态蛇形卷积（Dynamic Snake Convolution）并以血管分割作为辅助任务，利用 MA 与毛细血管的解剖依附关系提供空间约束；若 SE/EX 混淆严重，在解码器的跳跃连接处嵌入 CBAM 通道-空间注意力模块，增强模型对两类外观相似病灶的区分能力；若整体 mIoU 提升遇到瓶颈，引入多尺度特征金字塔（FPN）并结合滑窗式高分辨率推理，从根本上缓解因 512×512 缩放导致的 MA 分辨率损失问题。

每一项改动均遵循单变量原则——每次只改变一个因素并与上一版本对比，保留使验证集 mIoU 提升的改动，逐步叠加，最终形成可复现的最优配置。

其余可引入模型：

RTNet：利用病理学关联增强微小病灶检测

模块介绍：该模块的核心是 Relation Transformer Block (RTB)，它包含两重机制：（1）Self-Attention，学习同一病灶之间的全局依赖关系；（2）Cross-Attention，利用眼底图像中的血管（Vessels）作为解剖学先验，与病灶特征进行交互，缓解因复杂眼底结构导致的病灶检测模糊问题。

CMAC-Net：专为眼底病变设计的级联多尺度网络

模块介绍：该网络的核心创新在于（1）Mobile Dynamic Attention Convolution (MDAC)：采用大核动态注意力卷积，保留高分辨率特征，同时分离不同尺度的病变特征，对微小病灶分割尤其关键；（2）Cascade Progressive Context Fusion (CPCF)：渐进式级联上下文融合模块，有效融合不同层级信息，避免语义冲突。

SegDRoWS：参数量仅 2.27M 的全阶段多尺度特征融合网络

模块介绍：该网络的核心设计是（1）Intra-stage Multi-scale Feature Fusion (IMFF)：在每个编码器阶段内部，并行使用不同大小的卷积核以提取并融合多尺度特征；（2）Detail-Preserved Inter-stage Feature Fusion (DIFF) 和 Edge Guidance Branch (EGB)：在融合不同阶段特征的同时保留细节信息。

DRSeg：多注意力与多尺度监督的闭环增强框架

模块介绍：该框架采用三个递进式注意力模块形成闭环增强：（1）多感受野空间注意力：在编码阶段使用不同感受野的卷积同步捕捉病灶边缘；（2）动态权重跳跃连接：根据病灶密

度自动调节解码器的特征传递路径；(3) 跨特征图注意力模块 (AFMA)：将原始图像的低频结构与编码器高频特征动态融合，对微米级病灶的识别达到 92.3%。