

基于深度学习的眼底病灶分割

Fundus Lesion Segmentation via Deep Learning

大学生创新创业训练项目 · 中期汇报

何悠然、马骥裕、王子心、孙乐洋、吴晓雨

2026年6月

汇报提纲

01

数据集介绍

DDR数据集 · 类别不均衡挑战

02

自构建模型

YOLO (分类+分割) · U-Net (分割)

03

已复现论文模型

M2MRF · HRDecoder · SMP

04

实验结果对比

多模型横向比较

05

未来工作规划

架构横评 · 系统性优化

数据集

DDR (Diabetic Retinopathy Dataset)

任务类型

像素级语义分割 + 疾病分级 (0-4级)

分割图像数

757 张眼底图像 (带病灶标注)

标注类别

EX (硬性渗出) / HE (出血) / MA (微血管瘤) / SE (软性渗出)

图像分辨率

1500×1100 ~ 3200×2400 像素 (多来源、不均一)

对比数据集

IDRiD (516张, 分辨率统一4288×2848, 标注质量更高)

数据集划分


训练集 338张

背景占比: 99.09%



验证集 149张

背景占比: 99.56%



测试集 270张


背景占比: 98.94%



核心挑战：极度类别不均衡

01 Dataset

训练集各类别像素占比 (总像素 88,604,672)



背景/MA 像素比

2,712 : 1

背景/SE 像素比

1,031 : 1

背景/EX 像素比

368 : 1

前景总占比

0.91%

直接用标准CE Loss 训练会导致模型预测全为背景 (类别崩塌)

YOLO (分类 + 分割)

- ▶ YOLO11s-cls: DR 0-4级五分类
- ▶ YOLO-Seg: 病灶实例分割
- ▶ 核心创新: Focal Loss + 序数惩罚
- ▶ SimAM 3D注意力机制嵌入
- ▶ 切片训练 (Targeted Patch Training)

分类 **Top-1: 81.2%**
分割 **mAP@50: 31.6%**

U-Net (语义分割)

- ▶ 标准编码-解码架构 (自搭建)
- ▶ CLAHE+Gamma 眼底图像预处理
- ▶ 前景偏置 Patch 采样 (80%前景)
- ▶ Focal Tversky Loss ($\beta > \alpha$)
- ▶ ReduceLROnPlateau + 早停机制

验证集 **mIoU: 0.057**
测试集 **mIoU: 0.097**

分类任务模块


- **Ben Graham 对比度增强** — 均匀化光照，凸显血管
- **Focal Loss ($\gamma=2$) + 类别权重** — 梯度向稀少类 (1/3级) 倾斜
- **序数惩罚 (Ordinal Penalty)** — 跨级误诊额外惩罚 $\times 0.2/\text{级}$

分割任务模块

- **SimAM 3D注意力机制** — 嵌入C3k2 backbone与检测头之间
- **Hybrid Focus-Dice Loss** — Focal $\times$ Tversky 复合损失
- **切片训练 (1024 $\times$ 1024小图)** — 极大提升前景像素比例
- **两阶段推理: Detection定位 $\rightarrow$ Seg精细分割 $\rightarrow$ 还原坐标**

两阶段训练配置: 阶段一 384 $\times$ 384 / 50Ep / AdamW $\rightarrow$ 阶段二 512 $\times$ 512 / 60Ep / lr=1e-4

分类任务 (测试集, 3531张)



Top-1 Accuracy: **81.20%** (阶段一→二优化提升)

分割任务 (验证集, 切片分布)

mAP@50

31.61%

Precision

41.54%

Recall

37.12%

切片策略提升边缘判断精度, 但 MA 漏检率仍高达 83%

1

CLAHE + Gamma 预处理

RGB→LAB→CLAHE (L通道, clip=2.0) →RGB→Gamma ($\gamma=0.8$)
增强低对比度MA等微小病灶的可见性, 避免干扰色彩信息

2

前景偏置 Patch 采样

每Epoch生成1500个512×512 Patch: 80%以病灶质心为中心裁剪 (面积加权)
20%随机背景, 全图像内存缓存消除I/O瓶颈

3

Focal Tversky Loss

$Tl = (TP + \epsilon) / (TP + \alpha \cdot FP + \beta \cdot FN + \epsilon)$, 取 $\alpha=0.3$, $\beta=0.7$, $\gamma=0.75$
对漏检(FN)惩罚约为误检(FP)的2.3倍, 符合医学"宁误报、不漏检"原则

4

ReduceLROnPlateau + 早停

验证Loss连续5 Epoch无改善→学习率×0.5; 连续20 Epoch无改善→提前停止
100 Epoch上限, 保留最优checkpoint, 防止338张小数据集上过拟合



核心洞察

仅修改损失函数（阶段一→三）不足以解决 109:1 的类别不均衡问题。必须从数据采样层面同步介入，确保每个 Batch 中前景像素占有足够比例，损失函数的梯度信号才能真正作用于病灶检测学习。

类别	验证集 IoU	测试集 IoU	说明
Background (背景)	0.9877	0.9824	分割良好 (因主导地位)
MA (微血管瘤)	0.0193	0.0122	检测极弱, 占比仅0.037%
HE (出血)	0.0490	0.0800	低水平, 有轻微提升
EX (硬性渗出)	0.1593	0.2940	测试集EX面积更大导致其IoU较验证集提升
SE (软性渗出)	0.0000	0.0000	完全未检测到
前景均值 mIoU	0.0569	0.0965	

关键问题分析

SE = 0: SE标注仅1207个 (EX的1/18), 极度稀缺 + 与EX外观高度相似

MA极弱: 512×512后病灶仅1-3像素, 接近分辨率下限, 与噪声混淆

EX测试集↑: 测试集EX占比(0.377%)是验证集(0.071%)的5.3倍, 非真实泛化提升

M2MRF

Multi-to-Multi Feature Reassembly

Backbone	HRNetv2-W48 + FCNHead
输入尺寸	1024×1024
Loss	Binary Dice Loss

mIoU: 0.19 (测试集)

→ 多对多特征重组, 维持微小病灶激活

HRDecoder

High-Resolution Decoder

Backbone	HRNet-W48 + HRDecoder
输入尺寸	2048×2048
Loss	Binary Dice Loss

mIoU: 0.2851 (iter 20K)

→ 小波反馈精炼多尺度特征

SMP

Segmentation Models PyTorch


Backbone	U-Net + ResNet34/ImageNet
输入尺寸	512×512
Loss	CE + Dice + 类别权重

mIoU: 0.107 (验证) / 0.121 (测试)

→ ImageNet预训练弥补小数据不足

HRDecoder 详细实验结果 (最优 Iter 20K)

3.1 HRDecoder



最优 mIoU

28.51%

Iter 20K

最优 mF1

40.85%

Iter 20K

HE PPV

77.35%

精确率最高

SE IoU

34.84%

最优类别

HE 召回率偏低(30.27%)但精确率高(77.35%): 漏检严重但预测可信度高
MA 虽PPV=41%, 召回率(38%)相对均衡, 体现小目标检测固有难度

MA 检测极弱 ($IoU < 0.02$)

- ▶ 像素占比仅 0.037%，背景/MA 像素比 2712:1
- ▶ 缩放至 512×512 后病灶仅 1-3 像素，接近分辨率下限
- ▶ 外观为暗色小圆点，与血管噪声极难区分

SE 完全无法检测 ($IoU = 0$)

- ▶ 训练集仅 1207 个SE标注，约为EX的 1/18
- ▶ 与EX外观高度相似（均呈亮白斑块状）
- ▶ 测试集SE极少（0.036%）导致评估难度更高

验证/测试集指标不一致

- ▶ EX测试集占比(0.377%)是验证集(0.071%)的5.3倍 → IoU 虚高
- ▶ SE测试集占比仅为验证集的29% → IoU 骤降
- ▶ 数据集未按像素比例分层采样，导致统计偏差

像素准确率 (>98%) 因背景主导在本任务中缺乏评估意义，应以前景 mIoU 和各类别 Dice 为核心指标

阶段一：完善主流架构横向对比

DeepLabV3+ (ResNet50/101) ← CNN类

HRNet-W48 ← CNN类

TransUNet ← CNN-Transformer混合

Swin-UNet ← CNN-Transformer混合

HRDecoder + M2MRF ← 已复现复用

统一数据管线 · 相同训练轮数 · 前景mIoU为主要指标

阶段二：系统性优化（基于最优模型）

训练策略: Warmup余弦退火 + AMP混合精度

数据增强: SE/MA类配额采样 + 颜色抖动 + CopyPaste

MA检测: 动态蛇形卷积 + 血管分割辅助任务

SE/EX区分: 解码器跳跃连接处嵌入CBAM注意力

分辨率: 多尺度FPN + 滑窗高分辨率推理

单变量原则：每次只改一个因素，逐步叠加最优配置

汇报总结

01

数据基础确认

DDR数据集类别极度不均衡，MA背景比2712:1，统一数据管线已就绪

02

双路模型均已训练

YOLO分类81.2%；U-Net阶段四突破崩塌，前景mIoU达0.057/0.097

03

三篇论文已复现

M2MRF、HRDecoder、SMP；HRDecoder最优mIoU 0.285

04

预训练价值明确

ImageNet预训练对稀少类别（SE）检测至关重要，将贯穿后续实验

05

路线图清晰

架构横评 → 单变量优化 → 最优配置固化，目标超越公开基准

感谢聆听 · 敬请指导